Clase 7: De la muestra a la población

Ley de los Grandes Números, Teorema Central del Límite e Intervalos de Confianza

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

La pregunta

La pregunta

¿Qué proporción de los trabajadores asalariados es pobre?

Por qué nos importa

- Es un **parámetro clave** para evaluar políticas públicas.
- Determina presupuestos de programas sociales.
- Definir el salario mínimo
- Definir las paritarias

El problema

Para responderla con *certeza absoluta* habría que preguntarle a las **13 millones** de personas asalariadas que viven en el país. ¿Es factible?

Dos caminos posibles

Camino 1: Censo

Preguntarle a **toda** la población.

- Da la respuesta exacta.
- Cuesta cientos de millones de dólares.
- Se hace cada 10 años.
- No sirve para tomar decisiones *ahora*.

Camino 2: Muestra

Preguntarle a **una parte** de la población.

- Es la lógica de la EPH.
- Rápido y barato.
- Da una respuesta *aproximada*.
- ¿Cuánto podemos confiar en ella?

Toda esta clase trata de responder esa última pregunta.

Población vs muestra

El vocabulario que vamos a usar toda la clase

Población

El conjunto **completo** de unidades sobre las que queremos saber algo.
Ej.: todas las personas que viven en Argentina.

Muestra

Un **subconjunto** de la población, idealmente seleccionado al azar.
Ej.: las $\sim$50.000 personas relevadas por la EPH.

Parámetro vs estadístico

- **Parámetro** (p, μ, σ): número que describe a la *población*. Es **desconocido y fijo**.
- **Estadístico** ($\hat{p}$, $\bar{x}$, s): número calculado en la *muestra*. Es **conocido y aleatorio**.

Pero, lo mismo sirve para negocios

- **Comportamiento usuarios web**: los usuarios que vemos en un período son una muestra de la población de usuarios
- **Características de los fraudes**: para detectar comportamiento fraudulentos, se usa información pasada ¿cómo sabemos que es generalizable? Lo pensamos como una muestra de la población
- **La población**: Es algo que no se alcanza. Mi muestra puede ser más grande o más chica, pero nunca va a ser la población. En el censo tampoco lo es porque la gente nace y muere todo el tiempo, todo cambia.

Un experimento mental con la EPH

Vamos a hacer trampa: por hoy, vamos a tratar a la EPH completa **como si fuera la población**. Así conocemos el "verdadero" valor del parámetro y podemos ver qué tan bien funciona el muestreo.

Nota: en la EPH real cada persona tiene un peso (PONDERA) que refleja a cuántas personas representa. Para mantener la simulación pedagógicamente limpia, hoy tratamos a cada persona del archivo como una unidad poblacional con peso 1. Por eso nuestro p "verdadero" puede diferir del que publica INDEC. La inferencia con muestras complejas se ve en cursos de muestreo.

```
Tamaño de la 'población asalariada' (EPH individuos): 11.692 personas
Proporción real de pobres (parámetro p): 0.1644
```

La pregunta clave de la clase

Si yo tomo una muestra al azar de, digamos, 100 personas de esta población, ¿cuán cerca va a estar mi $\hat{p}$ del verdadero p?

Tomemos una muestra y veamos

```
Muestra 1 (n=100): p_hat = 0.14
Muestra 2 (n=100): p_hat = 0.21
Muestra 3 (n=100): p_hat = 0.13
```

¿Qué observamos?

Cada muestra da un número **distinto**. El estadístico $\hat{p}$ es una variable **aleatoria**: depende de qué personas hayan caído en la muestra.

Ley de los Grandes Números

¿Y si la muestra fuera más grande?

Repitamos el experimento haciendo crecer n desde 10 hasta 10.000.

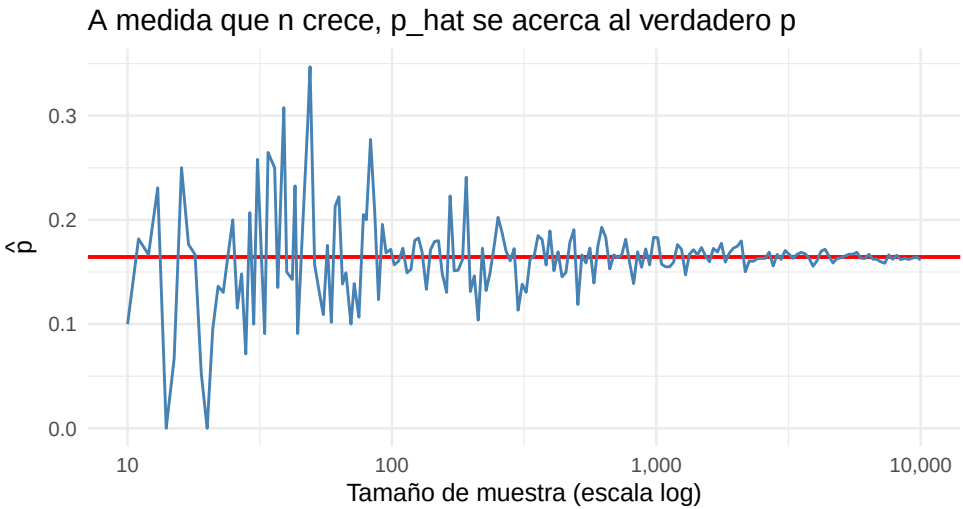

Ley de los Grandes Números (LGN)

Enunciado intuitivo

A medida que el tamaño de la muestra n crece, el promedio muestral se acerca al promedio poblacional.

$$\bar{X}_n \xrightarrow{n \to \infty} \mu$$

¿Qué nos dice y qué NO nos dice?

- **Sí dice:** con suficientes datos, nuestra estimación se vuelve confiable.
- **No dice:** cuán rápido converge.
- **No dice:** cuánto error tenemos con un *n concreto*.

El problema práctico

En la vida real **tenemos una sola muestra**. No podemos repetir el muestreo. ¿Cómo sabemos cuánto se equivoca?

Distribución muestral

Distribución muestral

Distribución muestral de $\hat{p}$

Es la distribución de los valores que tomaría $\hat{p}$ **si pudiéramos repetir** el muestreo infinitas veces, cada vez con un n fijo.

Es una distribución **hipotética** pero podemos *simularla* usando nuestra "población" EPH.

El experimento

1. Tomar una muestra de tamaño $n = 100$ y calcular $\hat{p}$.
2. Repetir 10.000 veces.
3. Graficar el histograma de los 10.000 $\hat{p}$.

Simulación de la distribución muestral (n=100)

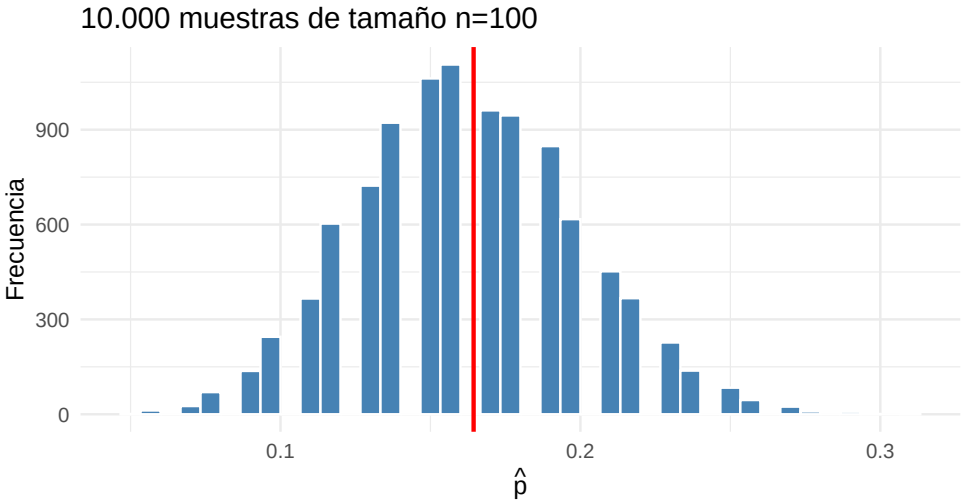


```
Media de las 10.000 p_hat: 0.1641   |  p verdadero: 0.1644
```

Tres observaciones cruciales

1. La distribución muestral está **centrada en el verdadero** p.
   El estimador es insesgado.
2. Tiene **su propio desvío**, llamado error estándar.
   $$SE(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$$
3. Tiene **forma de campana** (¡no es obvio que así fuera!).

Distinción que confunde a todo el mundo

- σ = desvío de la **población** (cuán dispersos están los individuos).
- $SE = \sigma/\sqrt{n}$ = desvío de la **distribución muestral** de $\bar{X}$ (cuán dispersas están las estimaciones).

Teorema Central del Límite

¿Qué pasa si aumenta N?

¿Cómo se distribuye el salario?

¿Qué pasa con la distribución del salario cuando aumenta el tamaño muestral?

¿Y si cambiamos n? Veamos qué pasa

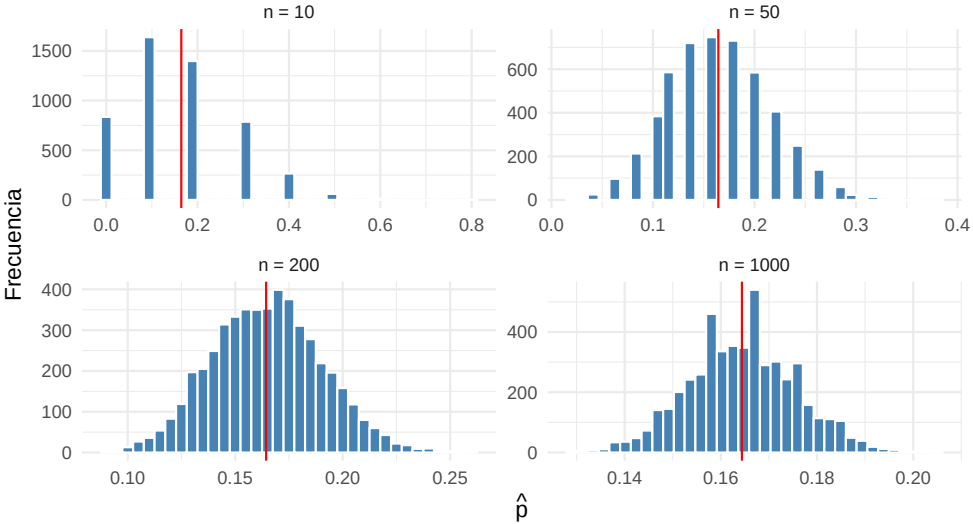

¿Qué pasa si aumenta N?

¿Cómo se distribuye el salario?

El salario se distribuye siempre igual, lo que cambia es la distribución de la media muestral

Teorema Central del Límite (TCL)

Enunciado intuitivo

Para n suficientemente grande, la distribución muestral de $\bar{X}$ es **aproximadamente Normal**, con media μ y desvío $\sigma/\sqrt{n}$, sin importar la forma de la población original.

$$\bar{X} \dot{\sim} \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Entonces...

No importa cómo sea la población. Puede ser asimétrica, bimodal, discreta, sesgada... la distribución de los promedios muestrales *siempre* tiende a ser Normal.

Veámoslo con una variable extremadamente asimétrica: el ingreso

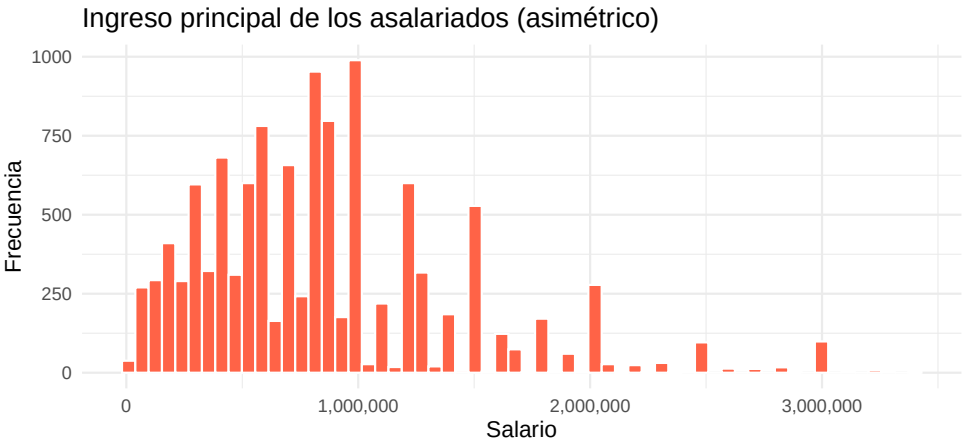

Claramente **no** es Normal.

Pero su distribución muestral... sí

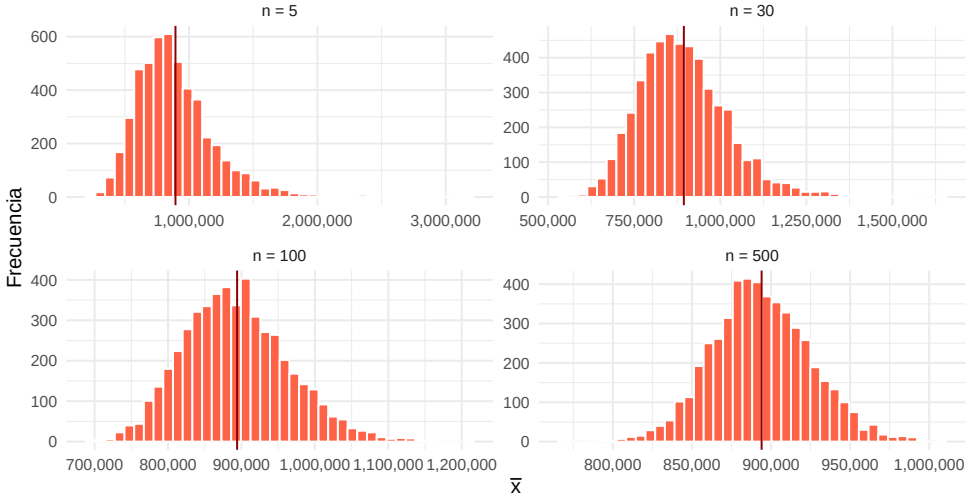

Con n=30 ya se ve la campana. Esto es el TCL en acción.

Cuidado: dos números distintos que se confunden

Cuando hablamos del TCL aparecen **dos** cantidades que son fáciles de confundir:

Los dos números

- n = **tamaño de cada muestra**. Es el número del que habla el TCL: a medida que n crece, la distribución de $\bar{X}_n$ se acerca a una Normal.
- B = **cuántas veces repetimos** el muestreo en una simulación. No aparece en el teorema: solo sirve para *dibujar* el histograma de la distribución muestral.

Lo más importante

El TCL es sobre n, no sobre B. En la vida real uno toma **una sola** muestra: el TCL nos dice de qué distribución vino ese único $\bar{X}$, *sin necesidad de repetir nada*.

Cuidado 2

Confusión recurrente

Cuando hablamos del TCL, nos referimos a la media de la variable, no a la variable en si misma. Es decir, la variable no empieza a comportarse como una normal cuando N tiene a infinito, sigue teniendo la misma distribución. Lo que tiende a una normal es la media muestral ($\overline{x} = \frac{\sum x_i}{n}$).

¿Cuándo "n es suficientemente grande"?

Reglas prácticas

- Para una variable razonablemente simétrica: $n \geq 30$ suele alcanzar.
- Para una proporción: $np \geq 10$ y $n(1-p) \geq 10$.
- Para variables muy asimétricas (ingresos, riqueza): conviene $n \geq 100$.
- Pero, siempre mientras más, mejor (dentro de lo razonable).

Por qué el TCL es la pieza clave

Nos permite saber **cómo se distribuye** nuestro estimador *sin haber repetido el muestreo*. Solo necesitamos:

- Que la muestra sea aleatoria.
- Que n sea suficientemente grande.

Un mapa para lo que viene: las "primas" de la Normal

La Normal no viene sola. A partir de ella se construyen otras distribuciones que vamos a ver en las próximas clases. Todas aparecen **cuando hacemos inferencia**, y todas se derivan del TCL.

La familia

- **Normal** ($\mathcal{N}$): distribución del promedio muestral cuando n es grande.
- **t de Student**: como la Normal pero con colas más gruesas. Aparece cuando estimamos σ con s y n es chico. *La usamos hoy mismo en los IC.*
- **Chi-cuadrado** (χ^2): suma de Normales al cuadrado. Aparece al comparar *frecuencias observadas vs esperadas* en tablas (test chi^2).
- **F de Fisher**: cociente de varianzas. Aparece al comparar *varianza entre grupos vs dentro de grupos* (ANOVA).

¿El TCL vale para cualquier estimador?

La pregunta

Vimos que la *media muestral* se vuelve Normal cuando n crece. ¿Pasa lo mismo con cualquier estadístico que calculemos sobre la muestra?

No

El TCL es un teorema sobre **sumas** (y promedios). Estadísticos que dependen de *valores extremos* de la muestra siguen distribuciones muy distintas, incluso con n enorme.

Veámoslo con el **máximo** del ingreso: una pregunta perfectamente razonable (¿cuál es el ingreso más alto en una muestra de 500 personas?) pero con un comportamiento asintótico totalmente distinto al de la media.

El máximo no se vuelve Normal, por más que crezca n

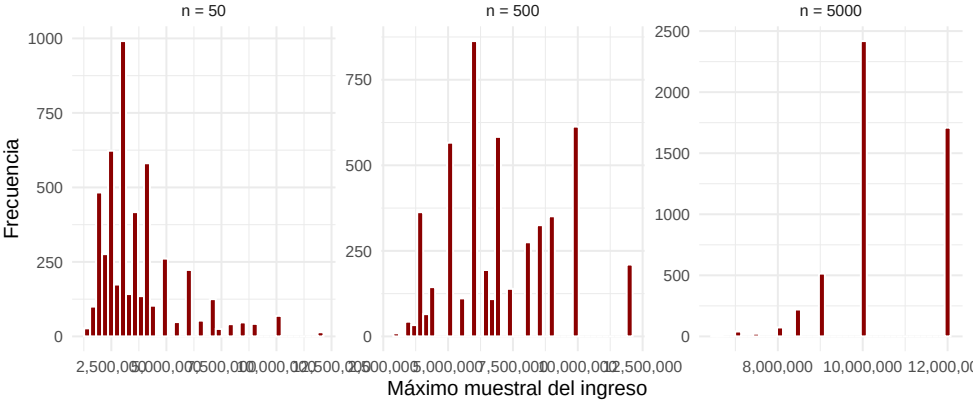

Aunque n crezca de 50 a 5000, la distribución del máximo **no** se vuelve simétrica: queda con cola larga a la derecha. Pertenece a otra familia (Gumbel/Fréchet, teoría de valores extremos), no a la Normal.

¿Por qué importa esto en la práctica?

Estadísticos "raros" que aparecen todo el tiempo

- **Máximos / mínimos**: pico de demanda eléctrica.
- **Cocientes de cuantiles**: ratio P90/P10 de ingresos (desigualdad).
- **Índices complejos**: Gini, Theil, HHI de concentración de mercado.

Para todos estos casos no tenemos una fórmula linda tipo $\sigma/\sqrt{n}$ ni la garantía del TCL.
Necesitamos otra herramienta $\rightarrow$ bootstrap.

Intervalos de confianza

De la distribución muestral al intervalo de confianza

Sabemos que $\hat{p} \sim \mathcal{N}\left(p,\ \sqrt{p(1-p)/n}\right)$.

Eso significa que el 95% de las veces, $\hat{p}$ cae a menos de $1{,}96 \cdot SE$ del verdadero p.

Dándolo vuelta

Si construimos el intervalo

$$\hat{p} \pm 1{,}96 \cdot \widehat{SE}, \qquad \widehat{SE} = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

entonces el 95% de esos intervalos van a contener al verdadero p.

Un IC concreto con nuestros datos

```
Muestra de n = 400 personas
p_hat = 0.1775
SE estimado = 0.0191
IC al 95 por ciento: [ 0.1401 , 0.2149 ]
p verdadero (que normalmente no conoceríamos): 0.1644
```

Lectura

Con una sola muestra de 400 personas conseguimos un intervalo angosto que **efectivamente contiene** al verdadero p.

Interpretación: lo que SÍ y lo que NO significa un IC

Interpretación INCORRECTA (la más común)

"Hay un 95% de probabilidad de que el verdadero p esté en el intervalo [0,38; 0,46]."
Falso. El verdadero p es un número fijo: o está en el intervalo o no está.

Interpretación CORRECTA (frecuentista)

"Si repitiéramos este procedimiento muchísimas veces, el 95% de los intervalos así construidos contendría al verdadero p."
La probabilidad está en **el procedimiento**, no en el parámetro.

La mejor forma de entenderlo: simular muchos IC

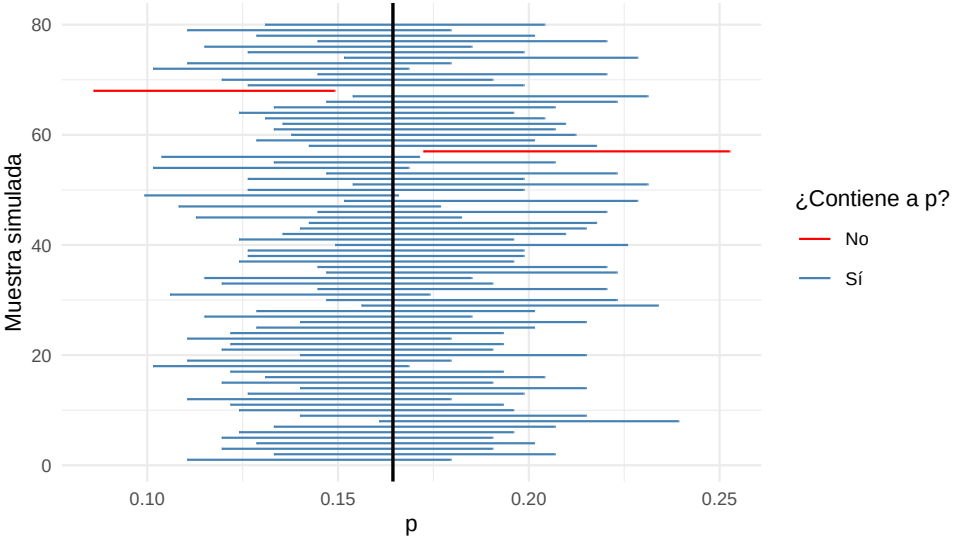

¿Y si no conozco σ o mi muestra es chica?

Distribución t de Student

Cuando estimamos σ con s y n es chico, $\bar{X}$ ya no se distribuye exactamente Normal. Sigue una distribución **t de Student** con $n-1$ grados de libertad.

Lo único que cambia

Reemplazamos el 1,96 por el valor crítico de la t:

$$\bar{X} \pm t_{n-1,\,0{,}975} \cdot \frac{s}{\sqrt{n}}$$

- Para $n = 10$: el valor crítico es $\approx 2{,}26$ (intervalo más ancho).
- Para $n = 100$: $\approx 1{,}98$ (casi igual al Normal).
- Para $n \to \infty$: la t converge a la Normal.

Prueba de hipótesis (un anticipo)

El primo cercano del intervalo de confianza

La pregunta de una prueba de hipótesis

En lugar de *estimar* un parámetro, queremos *testear* una afirmación sobre él.

Ej.: "La pobreza este trimestre subió respecto al anterior."

La conexión con los IC

- Si el valor hipotético **cae fuera** del IC al 95% $\Rightarrow$ rechazo la hipótesis al 5%.
- Si **cae dentro** $\Rightarrow$ no puedo rechazarla.
- Es la **misma matemática** mirada desde otro ángulo.

Lo desarrollamos en profundidad en la próxima clase.

¿Y todo esto para qué sirve en ciencia de datos?

La inferencia está atrás de todo

A/B testing

Una empresa cambia el botón de su web. ¿La nueva versión genera más clicks? Comparar dos proporciones $\Rightarrow$ IC de la diferencia $\Rightarrow$ decisión.

Evaluación de modelos de ML

Mi modelo tiene 87% de *accuracy* en el test set. ¿Cuán confiable es ese número? Es un $\hat{p}$ con su propio IC.

Encuestas y *polling* electoral

"Candidato X: 42% $\pm$ 3%". Ese $\pm$ es exactamente $1{,}96 \cdot SE$.

Y nos lleva a bootstrap

La pregunta

¿Y si mi estadístico no es una media y no tengo fórmula para su SE? (mediana, percentil 90, índice de Gini, ratio P90/P10...)

La idea del bootstrap (Efron, 1979)

Si no puedo repetir el muestreo de la población, voy a **remuestrear con reemplazo** mi propia muestra muchas veces y usar eso como aproximación de la distribución muestral.

La clave

El bootstrap funciona porque la LGN garantiza que nuestra muestra "se parece" a la población. Es inferencia estadística **computacional**, sin fórmulas cerradas. Es la base de `ranger`, `xgboost`, `caret`, `tidymodels`...

La receta del bootstrap, paso a paso

1. Tengo una muestra de tamaño n.
2. Saco una **nueva muestra de tamaño n con reemplazo** de mi muestra original. Algunas observaciones aparecen varias veces, otras ninguna.
3. Calculo mi estadístico (mediana, Gini, lo que sea) sobre esa "remuestra".
4. Repito los pasos 2-3 muchas veces ($\mathbf{B = 1000, 5000, 10000}\ldots$).
5. Tengo B valores del estadístico $\rightarrow$ esa es mi **distribución muestral aproximada**.
6. De ahí salen el SE (desvío de los B valores) y el IC (cuantiles 2.5% y 97.5%).

La intuición clave

La muestra original es a la población lo que cada remuestra es a la muestra original. Estamos *simulando* el proceso de muestreo que no podemos repetir en la realidad.

Validación: ¿el bootstrap "acierta" cuando sí tenemos fórmula?

```
SE analítico (fórmula): 37346.9
SE bootstrap (5000 rep): 37522.8
```

Cuando *sí* hay fórmula (caso de la media), el bootstrap llega esencialmente al mismo número. Esto nos da confianza para usarlo en los casos donde **no** hay fórmula.

Bootstrap en acción 1: IC para la mediana del ingreso

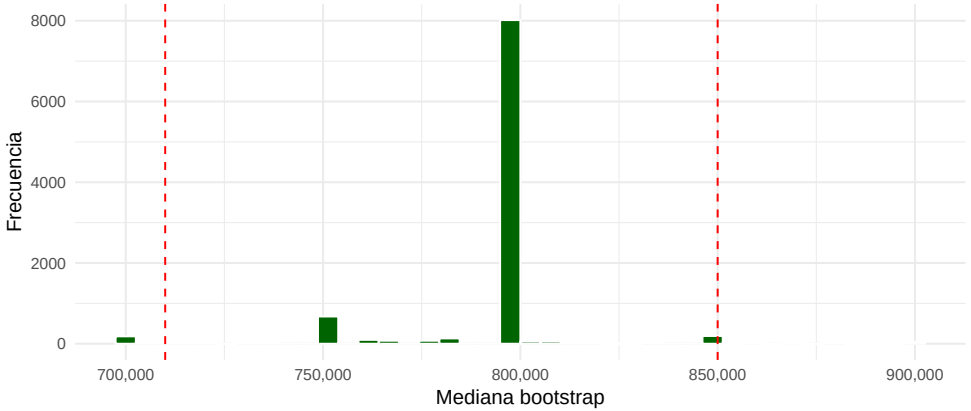


```
IC 95% para la mediana: [ 710.000 , 850.000 ]
```

Bootstrap en acción 2: IC para el índice de Gini

Esto es **exactamente** el tipo de estadístico para el que no hay una fórmula simple de SE, y donde el bootstrap brilla.

```
Gini puntual: 0.391   |  IC 95%: [ 0.354 , 0.426 ]
```

Sin haber escrito una sola fórmula de error estándar, tenemos un IC válido para una medida de desigualdad. Esa es la potencia del bootstrap.

Graficamente

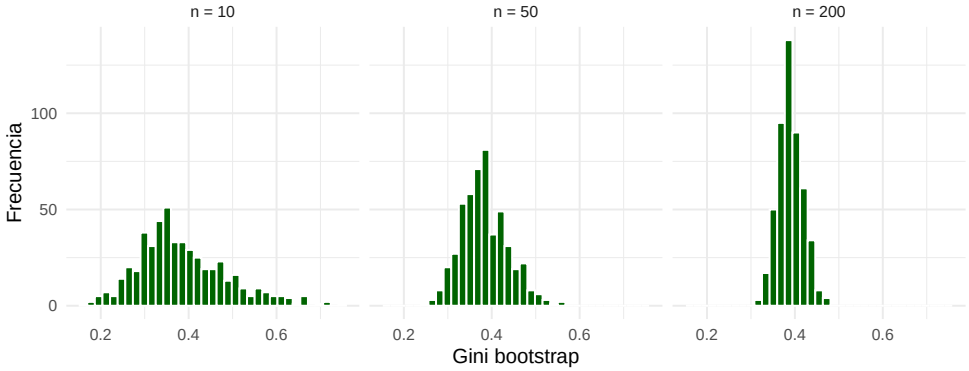

Entonces, bootstraping. . .

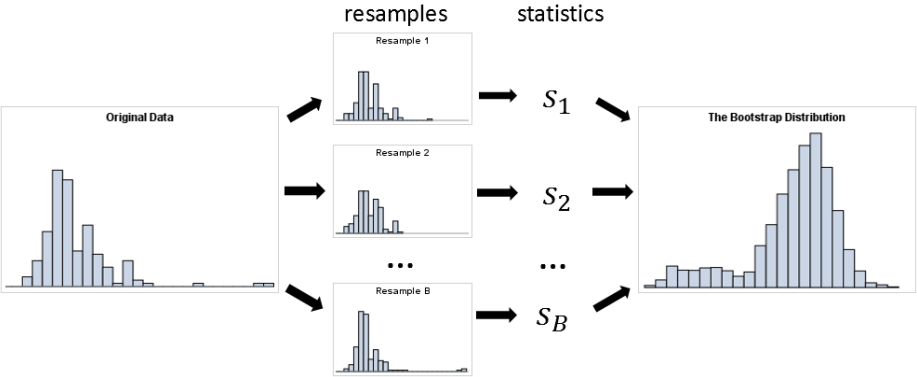

Cuidado: el bootstrap no hace todo

¿Qué pasa con los máximos y mínimos?

Es justamente uno de los casos donde el bootstrap **también falla**. Si remuestreamos con reemplazo, el máximo de la remuestra nunca puede superar al máximo de la muestra original $\rightarrow$ la distribución bootstrap queda "pegada" contra ese tope.

Regla práctica: el bootstrap funciona muy bien para estadísticos "suaves" (medias, medianas, cuantiles centrales, Gini, coeficientes de regresión) y falla para estadísticos que dependen de valores extremos. Para esos casos hay variantes (subsampling, bootstrap-m de n) que no llegamos a ver (o quizás sí, veremos).